Drugi čas - teorija

Veličina zapisa regularnog izraza brzo raste kako raste složenost regularnog jezika. Radi skraćivanja zapisa i povećanja čitljivosti, uvode se tzv. **prošireni regularni izrazi** koji predstavljaju kraće zapise nekih osnovnih regularnih izraza.

Prošireni regularni izraz	Opis
`[`$a_1a_2\ldots a_n$`]`	a_1`|`a_2`|...|`a_n
`[^`$a_1a_2\ldots a_n$`]`	Svi karakteri iz `ASCII` tabele osim karaktera iz skupa $\{a_1, a_2, \ldots, a_n\}$.
`[`a_1`-`a_n`]`	Alternacija karaktera od a_1 do a_n iz `ASCII` tabele.
`\w`	`[A-Za-z0-9_]`
`\W`	`[^A-Za-z0-9_]`
`\d`	`[0-9]`
`\D`	`[^0-9]`
`\s`	`[ \t\r\n\f]`, tj. sve moguće beline.
`\S`	`[^ \t\r\n\f]`
`.`	`[^\n]`, tj. sve osim novog reda.
`r+`	`rr*`, tj. jedno ili više pojavljivanja regularnog izraza `r`.
`r?`	ε`|r`, tj. nula ili jedno pojavljivanje regularnog izraza `r`.
`r{n}`	`rr...r`, gde je broj pojavljivanja regularnog izraza `r` tačno `n`.
`r{n,m}`	`rr...r`, gde važi $n \leq$ broj pojavljivanja regularnog izraza `r` $\leq m$.
`r{n,}`	`rr...r`, gde je broj pojavljivanja regularnog izraza `r` najmanje `n`.

Karakteri koji imaju specijalno značenje u okviru karakterske klase su: `-` (ukoliko se nađe između dva simbola), `\`, `]` i `^`.

Karakteri koji imaju specijalno značenje van karakterske klase su: `*`, `+`, `?`, `|`, `.`, `\`, `(`, `)`, `[` i drugi.

Za **oduzimanje specijalnog značenja** koristi se karakter `\` (*backslash*).

Gramzivost ili **pohlepnost** – poklapanje izraza vrši se u poslednjem trenutku kada je to moguće. Gramzivi operatori su `*`, `+`, `?` i `{ }`. Oduzimanje gramzivosti može se postići korišćenjem operatora `?` nakon gramzivog operatora.

Nestrpljivost ili **lenjo izračunavanje** – ako u disjunkciji možemo prepoznati prvi disjunkt u tekstu, drugi se ne razmatra.

Sidra ne prepoznaju nijedan karakter, već se koriste prilikom definisanja pozicije na kojoj treba izvršiti poklapanje.

`^`	Poklapanje treba izvršiti na početku teksta. Ako je uključen *multiline* flag, poklapanje se vrši na početku linije.
`$`	Poklapanje treba izvršiti na kraju teksta. Ako je uključen *multiline* flag, poklapanje se vrši na kraju linije.
`\b`	Koristi se kao granica reči. Reč posmatramo kao `\w+`, pa je granica svaki prelaz između karaktera iz klase `\w` i karaktera iz klase `\W`.